Python Programming

Module: Web Crawling

Web Crawling

- Web Scrapping
- 컴퓨터 소프트웨어 기술로 웹사이트들에서 원하는 정보를 추출하는 것
- 방대한 분량의 웹문서를 사람이 구별하여 모으는 일은 불가능
  - 소프트웨어가 일하게 하라

Python Web Crawling

Get Simple Text from Web

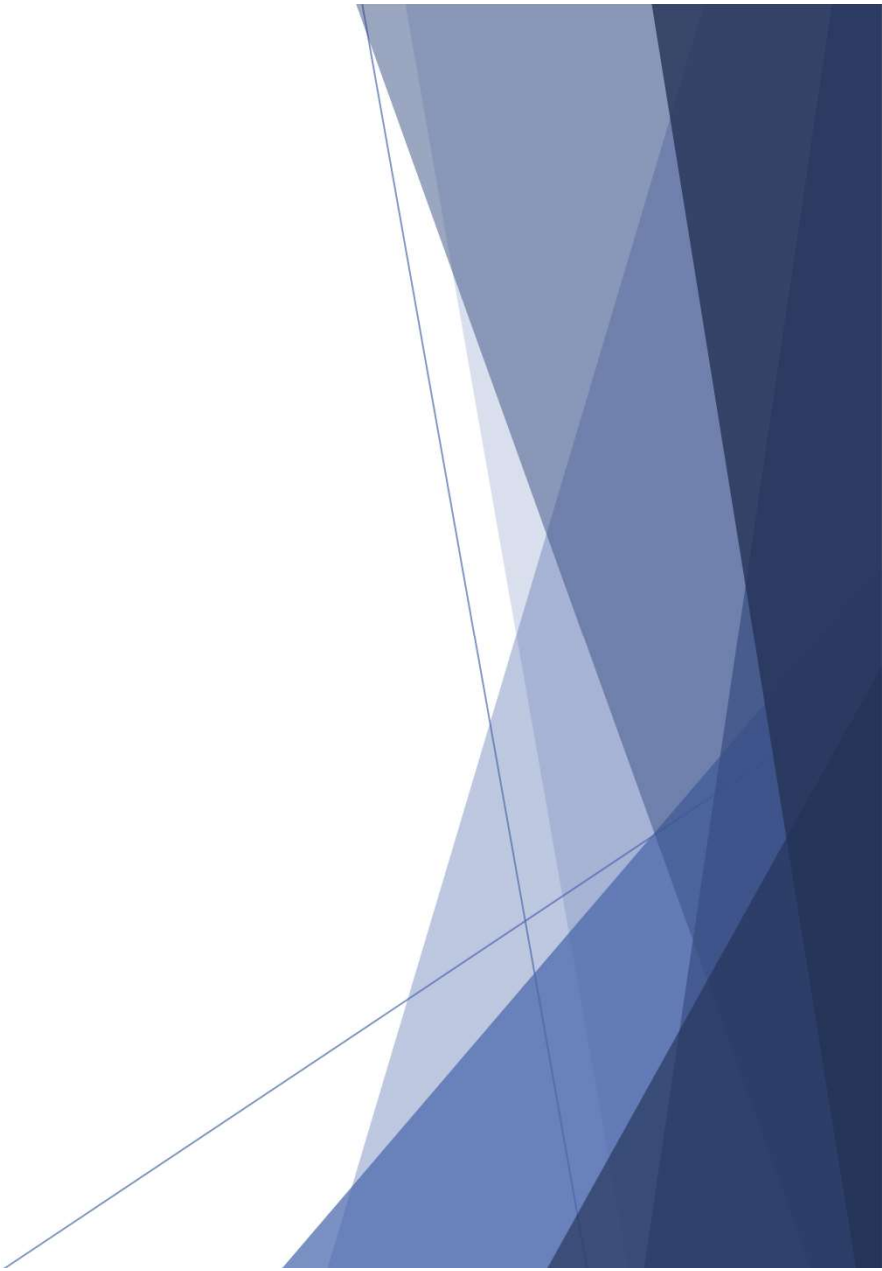

웹 크롤링을 지탱하는 기술

: HTTP Request and Response

HTTP : 비연결 지향 프로토콜

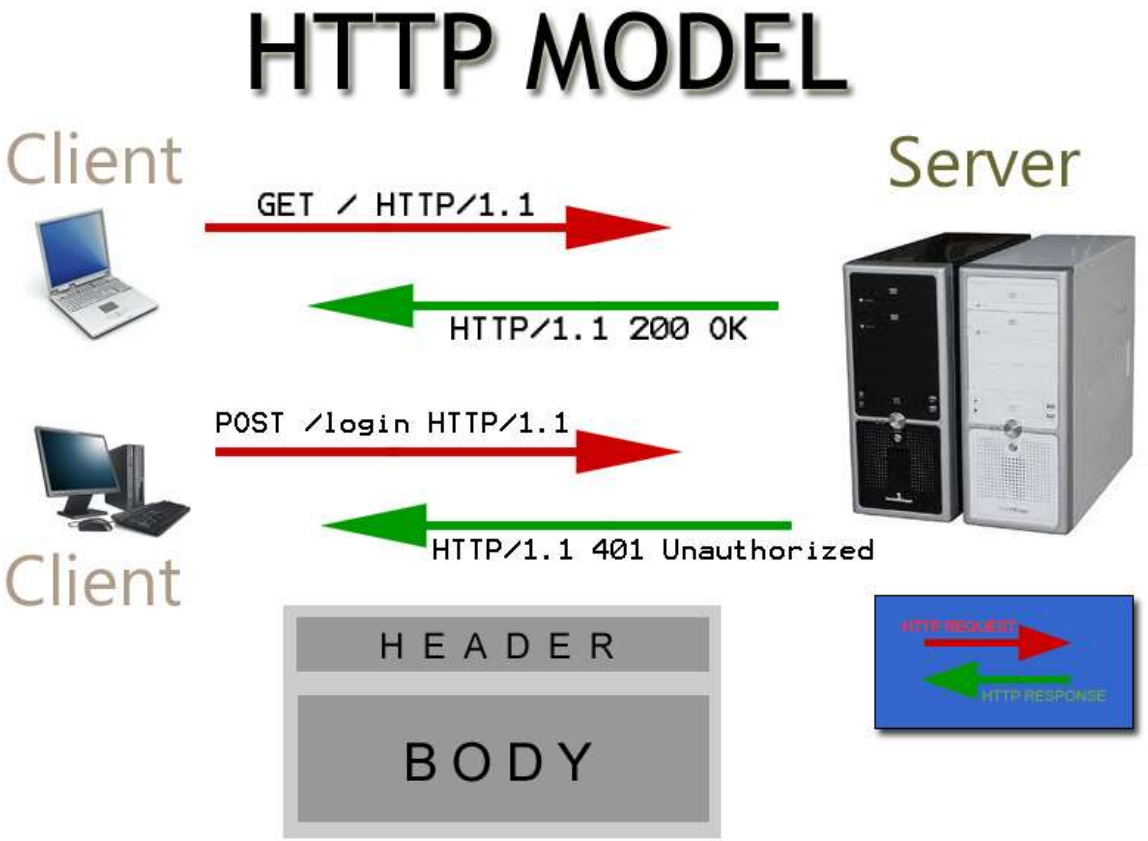

웹 크롤링을 지탱하는 기술

: URL and URI

URL : Uniform Resource Locator
URI : Uniform Resource Indicator
URN: Uniform Resource Name

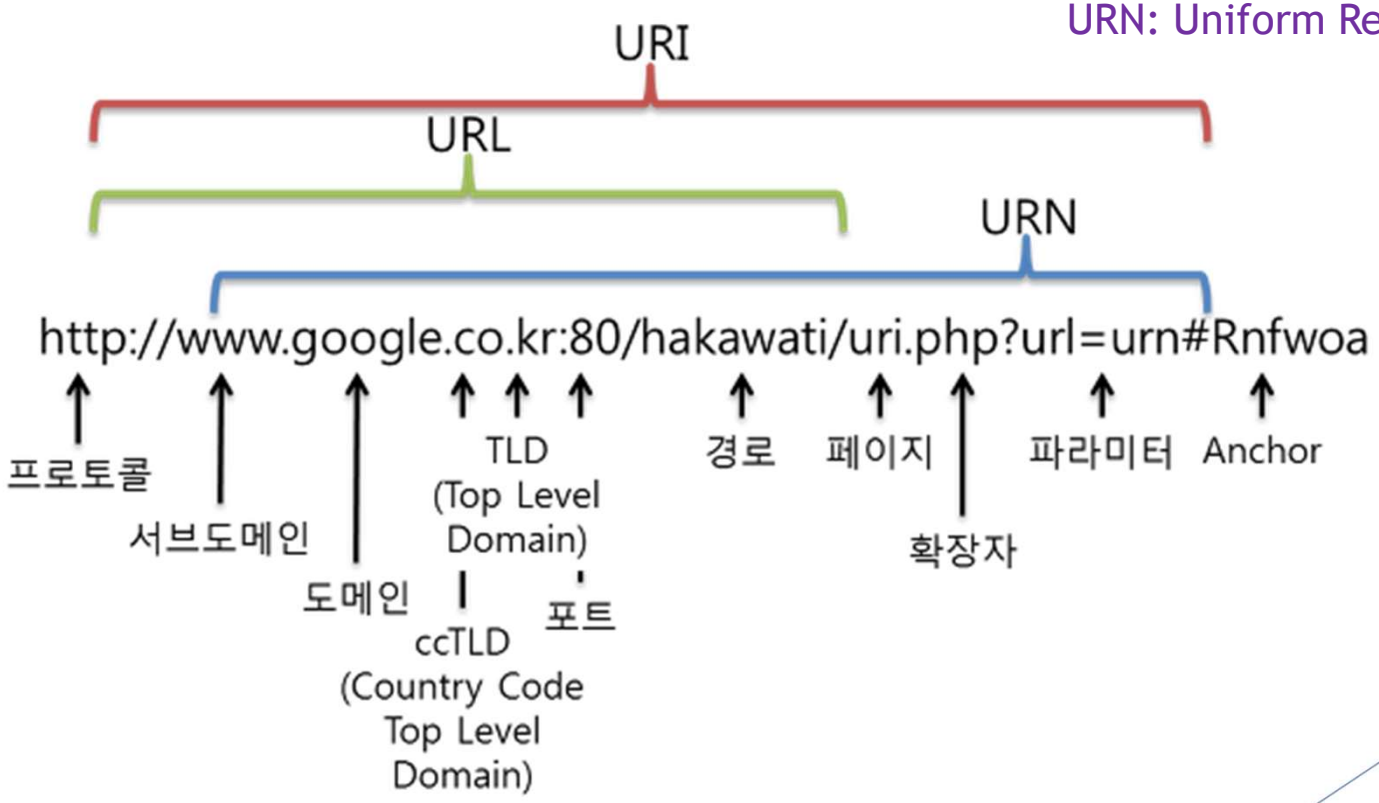

웹 크롤링을 지탱하는 기술
: urllib

- URL handling module
  - urllib.request : URL을 열고 읽어온다
  - urllib.error : urllib.request에서 일으키는 예외들을 포함
  - urllib.parse : url을 파싱하는 기술
  - urllib.robotparser : robots.txt 파일을 파싱

robot.txt : 검색엔진에게 수집을 제한하는 여러가지 정보를 담고 있는 파일

urllib를 이용한 텍스트 불러오기

```
# urllib로 웹 사이트 불러오기
import urllib.request

page = urllib.request.urlopen("http://www.gutenberg.org/cache/epub/12429/pg12429.txt")
print(page.read(100)) # 100글자만 불러오자
# 일부 깨지는 문자가 발생한다
# read가 완료되면 버퍼가 비어버리므로 다시 불러와야 한다
encoded = page.read().decode("utf-8")
print(encoded)print(encoded[:100]) # 100글자만 받아오자 너무 크다
```

받아온 텍스트를 대상으로 정규식 등을 이용,
분석을 시도한다

Python Web Crawling

with BeautifulSoup4

BeautifulSoup?

- Python의 대표적인 HTML 파싱 엔진
- urllib.request는 전달받은 response를 str로 전달하는 역할에 그친다
- BeautifulSoup은 이 텍스트를 객체 구조로 변환하여 '의미있는' 정보를 추출해 낼 수 있다

설치 : pip install bs4

BeautifulSoup
: 다음 뉴스를 받아와 보자

```
from urllib.request import Request, urlopen
from bs4 import BeautifulSoup

# HTTP GET Request
req = urlopen('http://media.daum.net')

# 먼저 req가 정상 코드를 받아왔는지 확인한다
print(req.getcode()) # HTTP 200은 정상값이다

if req.getcode() == 200:
    # html을 받아오자
    html = req.read()
    print(html) # 인코딩이 깨진다.

    html = html.decode("utf-8")
    print(html) # 정상이다
else:
    print("HTTP ERROR")
```

```
# 이제 soup을 만들어 즐겨보자
soup = BeautifulSoup(html, "html.parser") # soup을 만들었다
# print(soup.prettify())

print(soup.title)
# 타이틀에서 텍스트를 뽑아오자
print(soup.title.text)
```

DOM의 간단한 이해

- HTML은 Document Object Model 이라는 Tree 구조로 구성되어 있다
- HTML은 XML의 하위 집합
  - XML과 같이 Contents, Attribute 등을 이용, 내용과 속성에 접근할 수 있다
  - 단, XML처럼 강한 구속력이 작용하지는 않는다

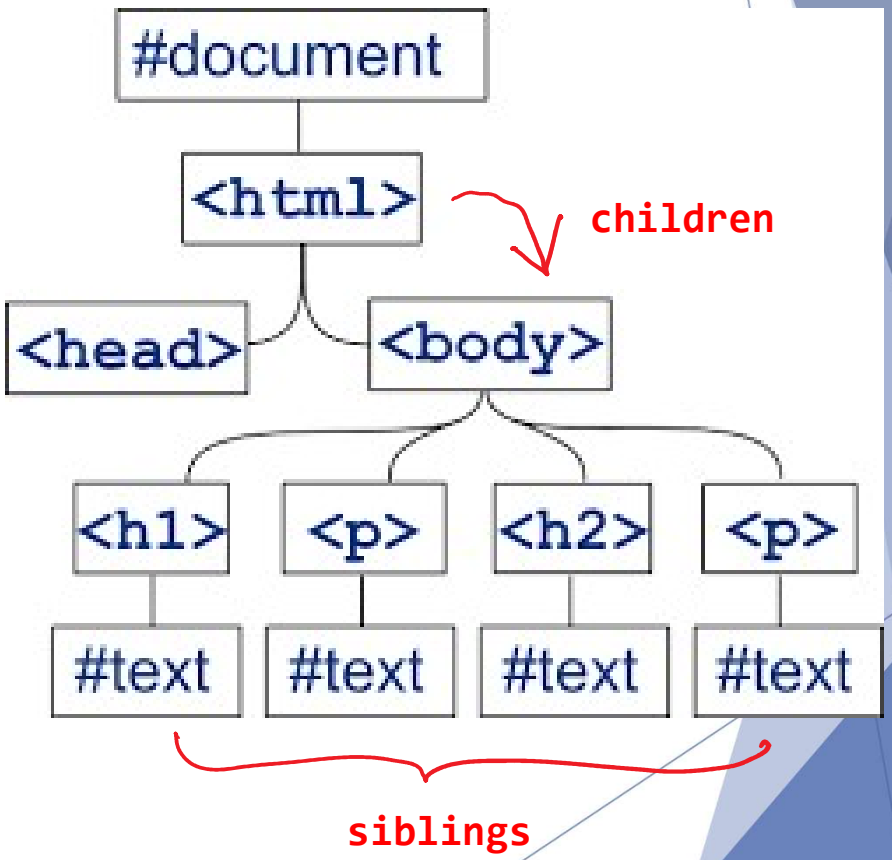

HTML에 대한 간단한 이해

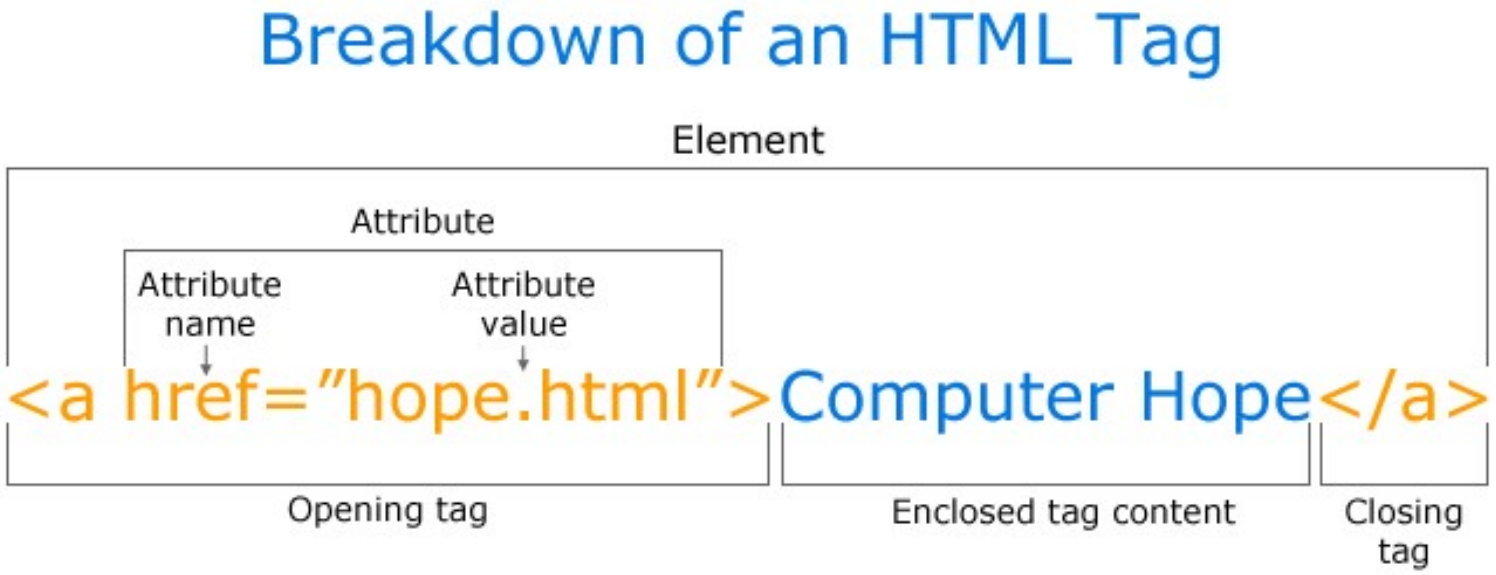

CSS class와 id

- HTML 태그는 id와 clsss를 가질 수 있다
  - id : 페이지 내 유일한 식별값
  - class : 중복 사용될 수 있는 스타일 값. 여러 개를 조합할 수도 있다

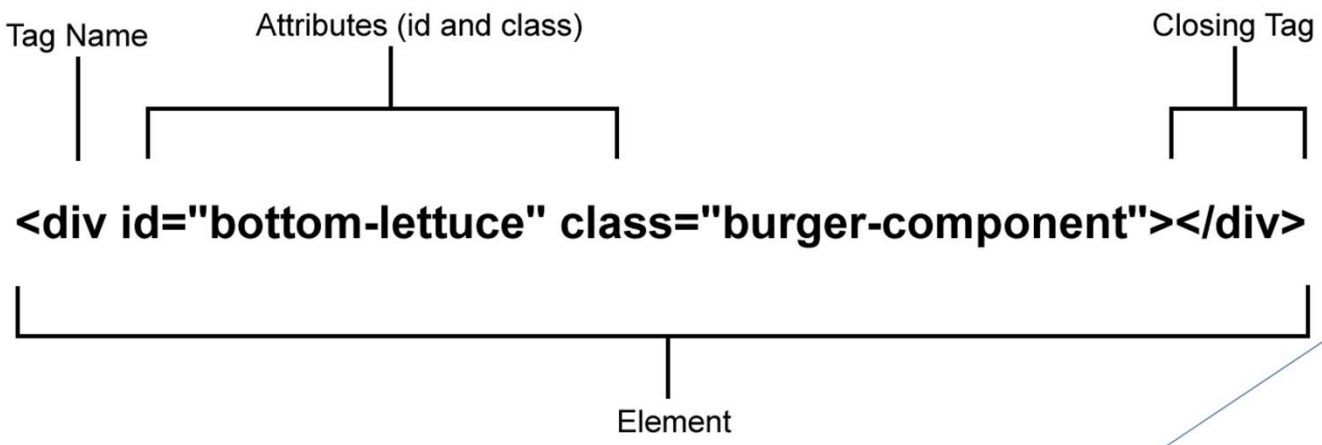

Understanding CSS Selectors

: Basic form

Selector	Example	Example description	CSS
.class	.intro	Selects all elements with class="intro"	1
#id	#firstname	Selects the element with id="firstname"	1
*	*	Selects all elements	2
element	p	Selects all <p> elements	1
element,element	div,p	Selects all elements and all <p> elements	1
element element	div p	Selects all <p> elements inside elements	1
element>element	div>p	Selects all <p> elements where the parent is a element	2
element+element	div+p	Selects all <p> elements that are placed immediately after elements	2

Understanding CSS Selectors

: Attribute Selectors

Selector	Example	Example description	CSS
[*attribute*]	[target]	Selects all elements with a target attribute	2
[*attribute=value*]	[target=_blank]	Selects all elements with target="_blank"	2
[*attribute~=value*]	[title~=flower]	Selects all elements with a title attribute containing the word "flower"	2
[*attribute|=value*]	[lang|=en]	Selects all elements with a lang attribute value starting with "en"	2
[*attribute^=value*]	a[src^="https"]	Selects every <a> element whose src attribute value begins with "https"	3
[*attribute$=value*]	a[src$=".pdf"]	Selects every <a> element whose src attribute value ends with ".pdf"	3
[*attribute*=value*]	a[src*="w3schools"]	Selects every <a> element whose src attribute value contains the substring "w3schools"	3

Understanding CSS Selectors
: Extended

Selector	Example	Example description	CSS
:before	p:before	Insert content before the content of every <p> element	2
:after	p:after	Insert content after every <p> element	2
:first-child	p:first-child	Selects every <p> element that is the first child of its parent	2
:last-child	p:last-child	Selects every <p> element that is the last child of its parent	3
:nth-child(*n*)	p:nth-child(2)	Selects every <p> element that is the second child of its parent	3
:nth-last-child(*n*)	p:nth-last-child(2)	Selects every <p> element that is the second child of its parent, counting from the last child	3
:nth-of-type(*n*)	p:nth-of-type(2)	Selects every <p> element that is the second <p> element of its parent	3
:nth-last-of-type(*n*)	p:nth-last-of-type(2)	Selects every <p> element that is the second <p> element of its parent, counting from the last child	3

페이지 분석

: 개발자 도구의 도움이 필요해(Chrome의 경우)

3. Selector 획득

#mArticle

1. 원하는 요소에서 우클릭
   검사 메뉴를 실행한다

2. selector를 찾아낸다

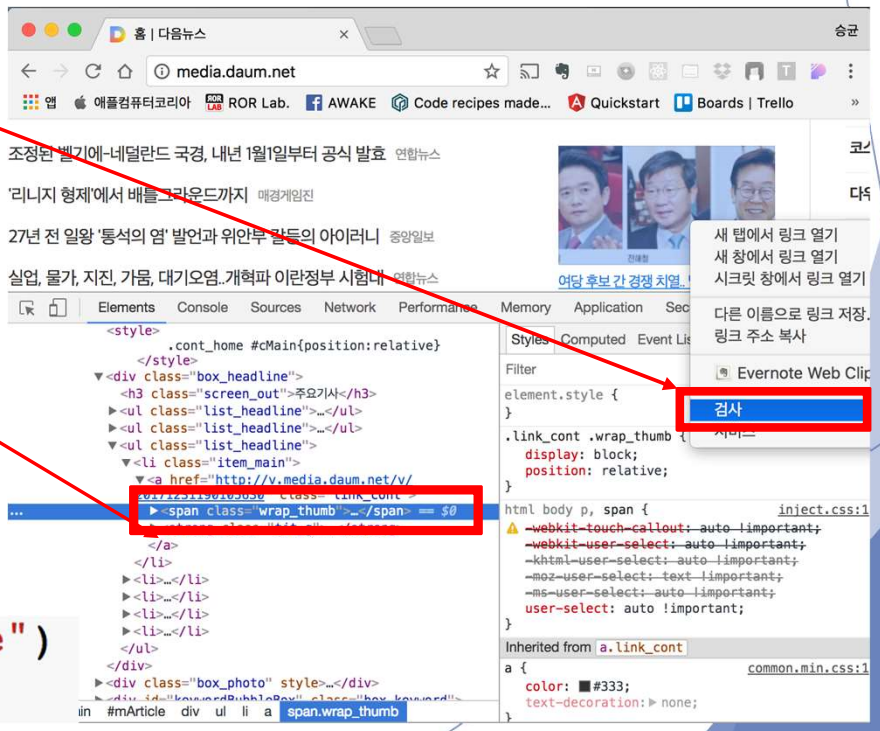


```
articles = soup.select("#mArticle")
print(articles)
```

BeautifulSoup
: CheatSheet

Basic

```
# https://www.crummy.com/software/BeautifulSoup/bs4/doc/
from bs4 import BeautifulSoup
soup = BeautifulSoup(html_doc, 'html.parser')


soup.title # <title>The Dormouse's story</title>
soup.title.name # u'title'
soup.title.string # u'The Dormouse's story'
soup.title.parent.name # u'head'

#various finder
css_soup.select("p.strikeout.body") # css finder
soup.p # <p class="title"><b>The Dormouse's story</b></p>
soup.p['class'] # u'title'
soup.a # <a class="sister" href="http://example.com/elsie" id="link1">Elsie</a>
soup.find_all('a') # [<a ..>, ..]
soup.find(id="link3") # <a class="sister" href="http://example.com/tillie" id="link3">Tillie</a>
for link in soup.find_all('a'):
    print(link.get('href')) # http://example.com/elsi, # http://example.com/lacie
```

http://akul.me/blog/2016/beautifulsoup-cheatsheet/

Make soup

```
from bs4 import BeautifulSoup

soup = BeautifulSoup(open("index.html"))
soup = BeautifulSoup("<html>data</html>")
```

Output

```
# HTML
soup.prettify() #pretty print
str(soup) # non-pretty print

# String
soup.get_text() #all text under the element
```

Search

```
#-------------------------
# css selector
#-------------------------
css_soup.select("p.strikeout.body")
soup.select("p nth-of-type(3)") # 3rd child
soup.select("head > title")
soup.select("p > a:nth-of-type(2)")
soup.select("p > #link1") # direct child
soup.select("#link1 ~ .sister")  # sibling
soup.select('a[href]') # existence of an attribute
soup.select_one(".sister")

# attribute value
soup.select('a[href="http://example.com/elsie"]') # exact attribute
soup.select('a[href^="http://example.com/"]') # negative match
soup.select('a[href$="tillie"]') # end match
soup.select('a[href*=".com/el"]') # middle match
```

Real Life Example

네이버 최신 영화 리스트

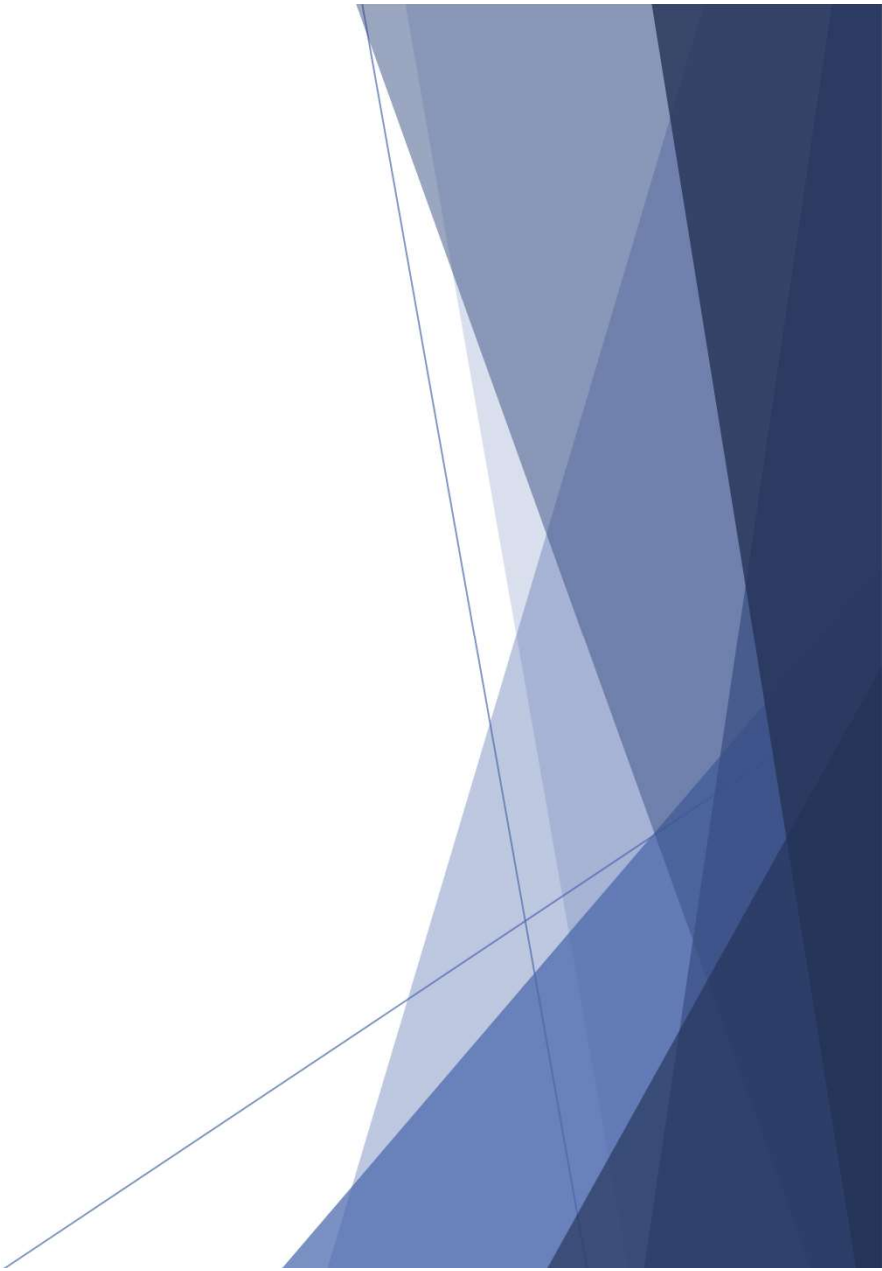

수집을 위한 준비

- URL 준비
  - Naver 홈 > 영화 > 상영작-예정작
    - http://movie.naver.com/movie/running/current.nhn
- HTML을 불러온다

```
from urllib.request import Request, urlopen
from bs4 import BeautifulSoup
request = Request("http://movie.naver.com/movie/running/current.nhn")
response = urlopen(request)
html = response.read()
# print(html[: 256]) # 코드가 깨진다... 인코딩을 변경하자
html = html.decode("utf-8")
# print(html[:256]) # 코드가 정상적이다
# 이제 BeautifulSoup으로 html을 정제하자
bs = BeautifulSoup(html, "html.parser")
print(bs.title)
print(bs.title.name)
# 이쁘게 표현해보자print(bs.prettify()[:1024])
```

영화 리스트의 Selector를 찾아보자

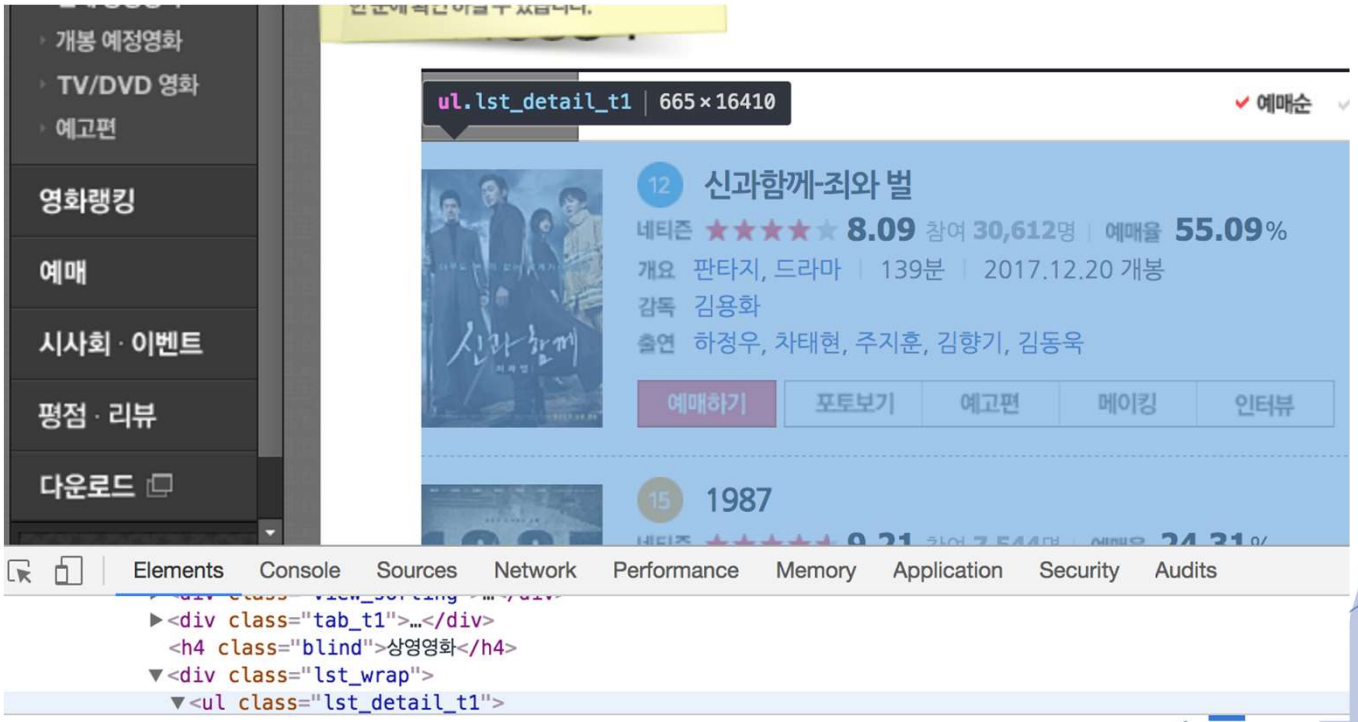

찾아낸 셀렉터 : class = “lst_detail_t1”인 ul

```
currents = bs.find("ul", attrs = {"class": "lst_detail_t1"})
```

수집 로직의 작성

```
for child in currents:
    try:
        titles = child.find("dt", attrs={"class": "tit"})
        for title in titles:
            try:
                if title.name == "a":
                    print(title.text, title['href'])
            except:
                pass
    except:
        pass
```

수집 로직의 작성
: Renewal Version

Using select method

```
from urllib.request import Request, urlopen
from bs4 import BeautifulSoup

request = Request("http://movie.naver.com/movie/running/current.nhn")
# print(dir(request))
# print(request.host)

response = urlopen(request)
html = response.read().decode("utf-8")
# print(html[:256])

# 이제 BeautifulSoup으로 html을 정제하자
bs = BeautifulSoup(html, "html.parser")

# print(bs.select(".lst_detail_t1"))
current_movies = bs.select(".lst_detail_t1 > li")
# print(type(current_list))

# print(current_list[0])

# for info in current_list:
#     print(info.prettify())

for movie in current_movies:
    titles = movie.select(".lst_dsc > .tit > a")

    for title in titles:
        print(title.text, title['href'])
```

Real Life Example

Naver API Call

Naver API

- 네이버에서 제공하는 각종 기능을 개발자에게 공개
- https://developers.naver.com/
- 지도, 뉴스, 검색 등 다양한 기능들을 외부에 공개하고 있으며, 네이버 사용자 관련된 기능들이 일부 오픈되어 있다

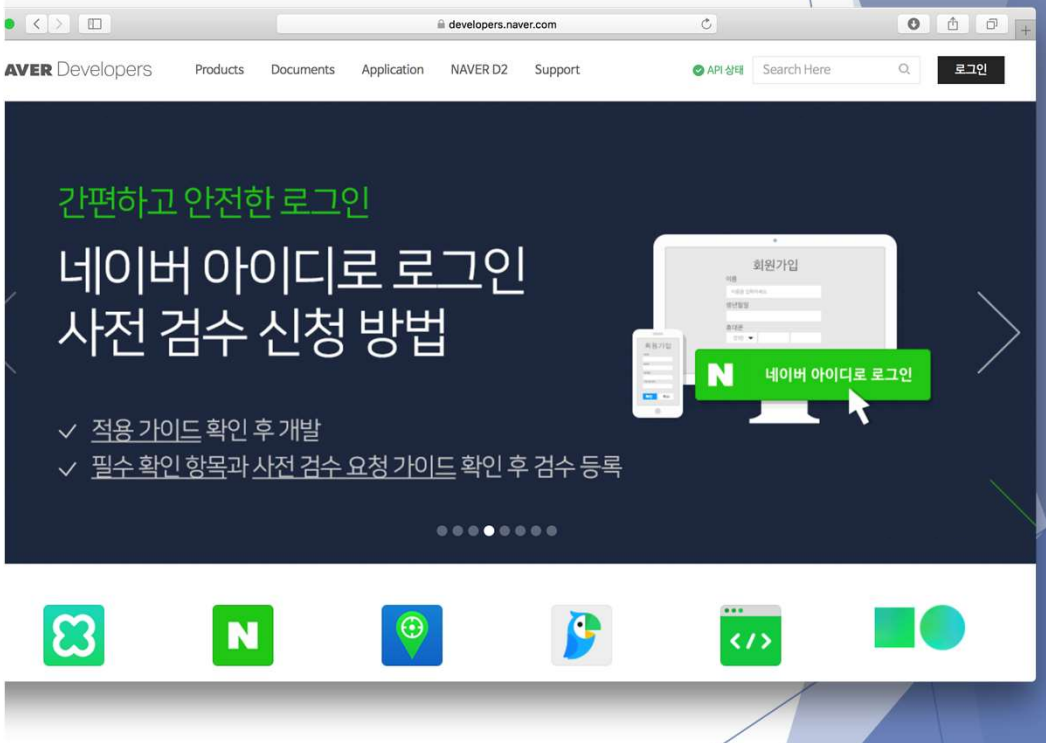

API 사용을 위한 준비

- API 사용을 위한 앱을 만들어야 한다

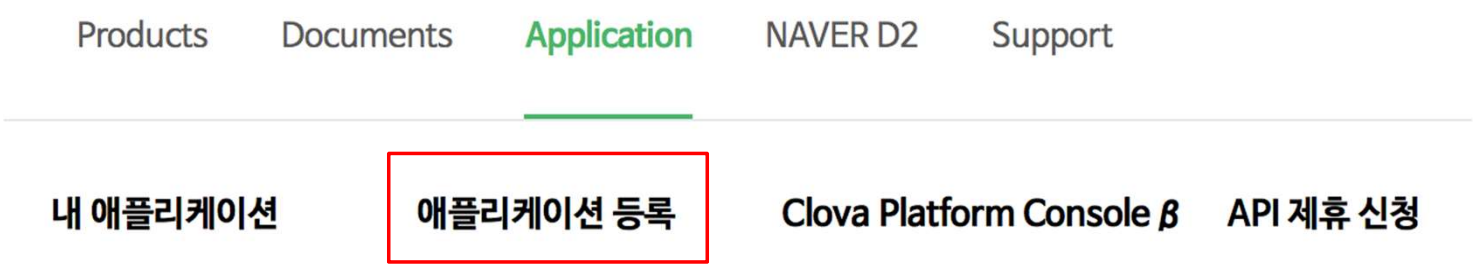

Application 등록

우리는 일단 file://dummy.py로 두자

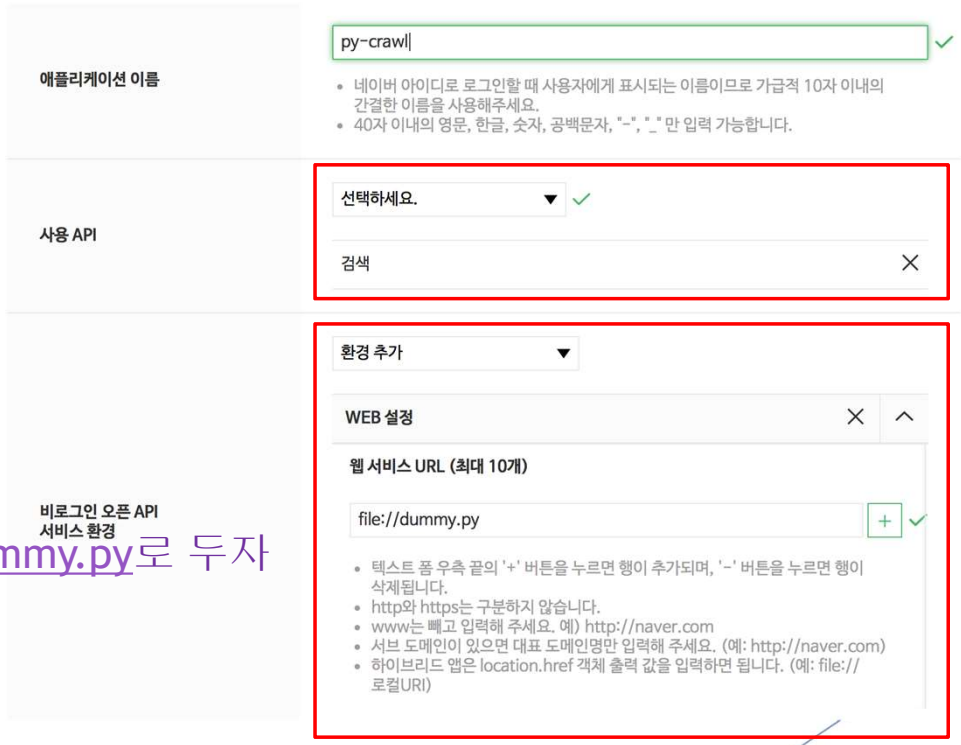

Client ID와 Client Secret 확인

매뉴얼의 확인

Documents > 서비스 API > 검색

서비스 API

데이터랩
검색
단축 URL
이미지캡차
음성캡차
네이버 공유하기
모바일앱 연동
네이버 오픈메인

2. API 기본 정보

메서드	인증	요청 URL	출력 포맷
GET	-	https://openapi.naver.com/v1/search/news.xml	XML
GET	-	https://openapi.naver.com/v1/search/news.json	JSON

3. 요청 변수 (request parameter)

요청 변수	타입	필수 여부	기본값	설명
query	string	Y	-	검색을 원하는 문자열로서 UTF-8로 인코딩한다.
display	integer	N	10(기본값), 100(최대)	검색 결과 출력 건수 지정
start	integer	N	1(기본값), 1000(최대)	검색 시작 위치로 최대 1000까지 가능

기본적인 수집

```
import urllib.request

client_id = "_DA93V_MBJrbEfDGz90k"
client_secret = "A3AGuyY2iH"

enc_text = urllib.parse.quote("북핵")
url = "https://openapi.naver.com/v1/search/news.json?query={}".format(enc_text)

request = urllib.request.Request(url)
request.add_header("X-Naver-Client-Id", client_id)
request.add_header("X-Naver-Client-Secret", client_secret)
response = urllib.request.urlopen(request)
rescode = response.getcode()

print(rescode)

if (rescode == 200):
    response_body = response.read()
    print(response_body.decode('utf-8'))
else:
    print("Error Code: %d" % rescode)
```

JSON

- JavaScript Object Notation
  - 최근에는 API 결과값을 전송할 때 XML보다 JSON을 더 많이 쓴다
  - 경량이고, 구조가 단순하여 쉽게 처리할 수 있다
  - 문자형, 수치형, 논리값, 배열, 사전 등 다양한 데이터형 지원


```
{
    hey: "guy",
    anumber: 243,
  - anobject: {
        whoa: "nuts",
      - anarray: [
            1,
            2,
            "thr<h1>ee"
        ],
        more: "stuff"
    },
    awesome: true,
    bogus: false,
    meaning: null,
    japanese: "明日がある。",
    link: http://jsonview.com,
    notLink: "http://jsonview.com is great"
}
```

수집 데이터를 json으로 가공
: 수집 로직의 개선

```
if (rescode == 200):
    response_body = response.read()

    json_rt = response_body.decode("utf-8")
    py_rt = json.loads(json_rt)

    news_list = py_rt['items']

    for news in news_list:
        print("title: {title} @ {pubDate}".format_map(news))

    # ==========
    for news in news_list:
        news['title']
        print("title: {title} @ {pubDate}".format_map(news))

else:
    print("Error Code: %d" % rescode)
```

Happy Crawling ☺